Metody Monte Carlo

Raport nr 1

Tadeusz Jagniewski

Spis treści

1 Zadanie 1: Symulacja dyskretnych zmiennych losowych (3 pkt) 1
1.1 Rozwiązanie 1

2 Zadanie 2: Symulacja ciągłych zmiennych losowych (4 pkt) 5
2.1 Rozwiązanie 5

3 Zadanie 3: Generowanie rozkładu normalnego metodą Boxa-Müllera (4 pkt) 9
3.1 Rozwiązanie: 9

4 Zad. 4. Metoda akceptacji (3 pkt) 14
4.1 Rozwiązanie: 14

1 Zadanie 1: Symulacja dyskretnych zmiennych losowych (3 pkt)

1. Napisz funkcję realizującą generator liczb losowych o rozkładzie dwupunktowym: $\mathbb{P}(X = 1) = p$, $\mathbb{P}(X = 0) = 1 - p$, gdzie $p \in [0, 1]$.
2. Napisz funkcję realizującą generator liczb losowych z rozkładu dwumianowego. Narysuj histogram dla przykładowej próby z tego rozkładu.
3. Napisz funkcję realizującą generator dla rozkładu Poissona (w raporcie zawrzyj obliczenia przygotowawcze). Narysuj histogram dla przykładowej próby z tego rozkładu.

1.1 Rozwiązanie

1.1.1 1)

```
gen_dwupunktowy <- function(n, p) {

  if (p < 0 || p > 1) {
    stop("Parametr p musi być w przedziale [0,1]")
  }

  u <- runif(n)
  x <- ifelse(u <= p, 1, 0)

  return(x)
}
#próba działania funkcji
set.seed(123)
proba_dwupunktowa <- gen_dwupunktowy(1000, p = 0.3)
```

Średnia empiryczna: 0.296, a teoretyczna wynosi 0.3.

Wariancja empiryczna: 0.2086, a teoretyczna wynosi 0.21.

1.1.2 2)

```
gen_dwumianowy <- function(m, n, p) {

  if (p < 0 || p > 1) {
    stop("Parametr p musi być w przedziale [0,1]")
  }
  if (n < 1) {
    stop("Parametr n musi być liczbą naturalną >= 1")
  }

  # Dla każdej z m prób generujemy n zmiennych Bernoulli i sumujemy
  wynik <- numeric(m)
  for (i in 1:m) {
    wynik[i] <- sum(gen_dwupunktowy(n, p))
  }

  return(wynik)
}
```

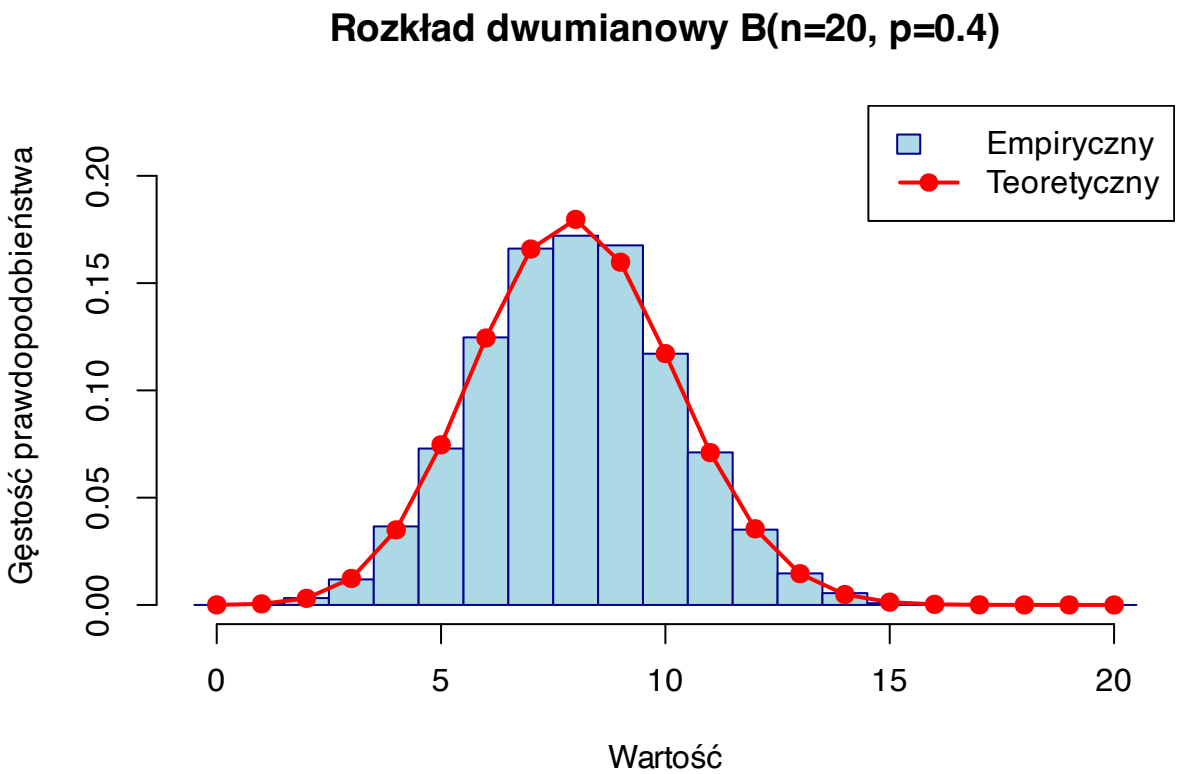

Rysunek 1: Histrogram generowanego rozkładu dwumianowego B(20, 0.4)

Rozkład dwumianowy B(n=20, p=0.4)

Średnia empiryczna: 8.007, a teoretyczna wynosi 8.

Wariancja empiryczna: 4.796, a teoretyczna wynosi 4.8.

Ten Generator daje bardzo zbliżone wyniki do prawdziwych

1.1.3 3)

Rozkład Poissona jest rozkładem dyskretnym. Jego funkcja masy prawdopodobieństwa dana jest wzorem:

$$P(X = k) = p_k = \frac{e^{-\lambda}\lambda^k}{k!} \quad \text{dla } k = 0, 1, 2, ...$$

gdzie $\lambda > 0$ jest parametrem intensywności. Dystrybuanta $F(k)$ to skumulowane prawdopodobieństwo:

$$F(k) = P(X \leq k) = \sum_{i=0}^{k} P(X = i) = \sum_{i=0}^{k} \frac{e^{-\lambda}\lambda^i}{i}$$

Dla rozkładów dyskretnych "odwrotność dystrybuanty" $F^{-1}(u)$ jest zdefiniowana jako:

$$F^{-1}(u) = \inf\{k \in \{0, 1, 2, ... \} : F(k) \geq u\}$$

Oznacza to, że szukamy najmniejszej liczby całkowitej k, dla której skumulowane prawdopodobieństwo F(k) jest większe lub równe u.

Kroki algorytmu dla jednej próby:

1. Wygeneruj liczbę losową u z rozkładu jednostajnego $U(0, 1)$.
2. Zainicjuj $k = 0$. Oblicz prawdopodobieństwo początkowe p_0 i ustaw je jako sumę skumulowaną S:

$$p_0 = P(X = 0) = \frac{e^{-\lambda}\lambda^0}{0!} = e^{-\lambda}$$

$$S = p_0$$

3. Sprawdź warunek: Czy $S \geq u$?

Jeśli TAK ($u \leq F(0)$): Zwróć $k = 0$.

Jeśli NIE ($u > F(0)$): Przejdź do pętli iteracyjnej (krok 4).

4. Wykonuj pętlę `while` (dopóki $S < u$):
   - Zwiększ k: $k \leftarrow k + 1$.
   - Oblicz kolejne prawdopodobieństwo: $p_k = \frac{e^{-\lambda}\lambda^k}{k!}$.
   - Zaktualizuj sumę: $S \leftarrow S + p_k$. (Teraz S przechowuje $F(k) = \sum_{i=0}^{k} p_i$).
5. Pętla zatrzyma się, gdy po raz pierwszy $S \geq u$. Znaleźliśmy wtedy k, które spełnia:

$$F(k - 1) < u \leq F(k)$$

6. Zwróć wartość k.

Algorytm ten jest dokładnie tym, co realizuje poniższa funkcja `gen_poisson`, gdzie zmienna `suma_p` odpowiada naszemu $S = F(k)$.

```
gen_poisson <- function(m, lambda) {
  if (lambda <= 0) {
    stop("Parametr lambda musi być dodatni")
  }
  wynik <- numeric(m)
```

```
  for (i in 1:m) {
    u <- runif(1)
    suma_p <- exp(-lambda)
    k <- 0
    while (suma_p < u) {
      k <- k + 1
      suma_p <- suma_p + (lambda^k) / factorial(k) * exp(-lambda)
    }
    wynik[i] <- k
  }
  return(wynik)
}
```

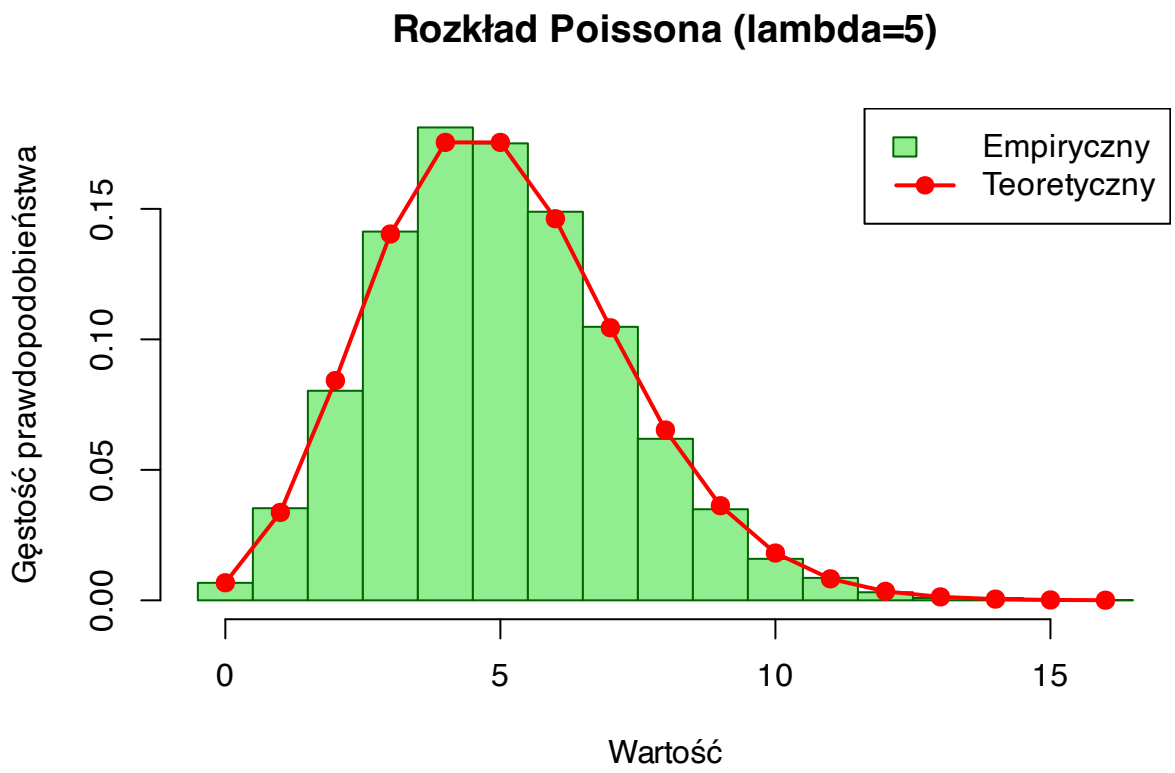

Rysunek 2: Histogram generowanego rozkładu Poissona (lambda=5)

Rozklad Poissona (lambda=5)

Srednia empiryczna: 4.9746, a teoretyczna wynosi 5.

Wariancja empiryczna: 4.8964445, a teoretyczna wynosi 5.

Ten generator również daje wyniki bardzo zbliżone do prawdziwych, ale w porównaniu do poprzedniego są nieco większe róznice między wartościami emipirycznymi, a teoretycznymi zwłaszcza jest to zauważalne jeśli chodzi o wariancję.

2 Zadanie 2: Symulacja ciągłych zmiennych losowych (4 pkt)

1. Zaimplementuj omówiony na wykładzie generator rozkładu wykładniczego. Narysuj histogram dla próby o rozmiarze $n = 2000$ wygenerowanej przy jego pomocy i nałóż na niego krzywą gęstości rozkładu wykładniczego.
2. Wyznacz dystrybuantę odwrotną dla rozkładu Weibulla o funkcji gęstości

$$f(x) = \frac{k}{\lambda^k} x^{k-1} e^{-(x/\lambda)^k} \mathbf{1}_{(0,+\infty)}(x), \quad x \in \mathbb{R},$$

   gdzie $k > 0$, $\lambda > 0$ (w raporcie zawrzyj odpowiednie obliczenia). Wykorzystaj ją do napisania funkcji realizującej generator liczb losowych z rozkładu Weibulla. Narysuj histogram dla próby o rozmiarze $n = 2000$ wygenerowanej przy jego pomocy i nałóż na niego krzywą gęstości rozkładu Weibulla.
3. Napisz funkcję realizującą generator liczb losowych z rozkładu Laplace'a z parametrem $\lambda > 0$ o gęstości:

$$f(x) = \frac{\lambda}{2} e^{-\lambda|x|}, \quad x \in \mathbb{R}.$$

   Narysuj histogram dla próby o rozmiarze $n = 2000$ wygenerowanej przy jego pomocy i nałóż na niego krzywą gęstości rozkładu Laplace'a.

2.1 Rozwiązanie

2.1.1 1.

```r
gen_exp <- function(n, lambda) {

  if (lambda <= 0) {
    stop("Parametr lambda musi być dodatni")
  }

  u <- runif(n)

  x <- (-1 / lambda) * log(u)

  return(x)
}
```

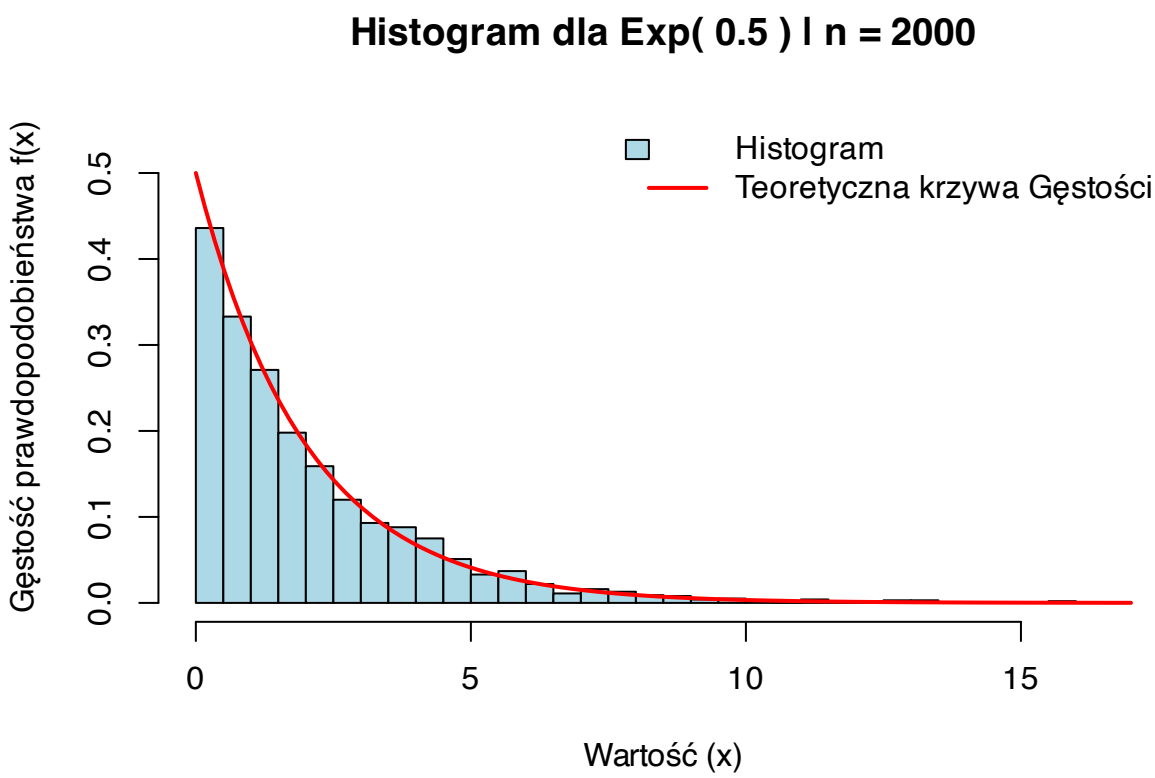

Rysunek 3: Histogram generowanego rozkładu wykładniczego Exp(0.5) o rozmiarze n=2000

Jak widać przy tak dużej próbie dane wygenerowane są bardzo zbliżone do prawdziwych.

2.1.2 2.

Dystrybuana Rozkładu weibulla ma postać:

$$F(x) = 1 - e^{-(x/\lambda)^k} \quad \text{dla } x \geq 0$$

Wyznaczenie Dystrybuanty Odwrotnej:

$$u = 1 - e^{-(x/\lambda)^k}$$

Przekształcamy algebraicznie, aby wyznaczyć x i wychodi nam, że:

$$x = \lambda \cdot [-\ln(1-u)]^{1/k}$$

Jest to nasza funkcja kwantylowa $F^{-1}(u)$.

Uproszczenie: Zauważmy (podobnie jak w przypadku rozkładu wykładniczego), że jeśli $U \sim U(0,1)$, to zmienna losowa $V = 1 - U$ również ma rozkład $U(0,1)$. Możemy więc dla uproszczenia zastąpić $1-u$ przez u w generatorze. Generator będzie zatem implementował wzór:

$$X = \lambda \cdot [-\ln(U)]^{1/k}$$

gdzie $U \sim U(0,1)$

```r
gen_weibull <- function(n, k, lambda) {

if (k <= 0 || lambda <= 0) { stop("Parametry k (kształt) i lambda (skala) muszą być dodatnie") }

u <- runif(n)

x <- lambda * (-log(u))^(1 / k)

return(x) }
```

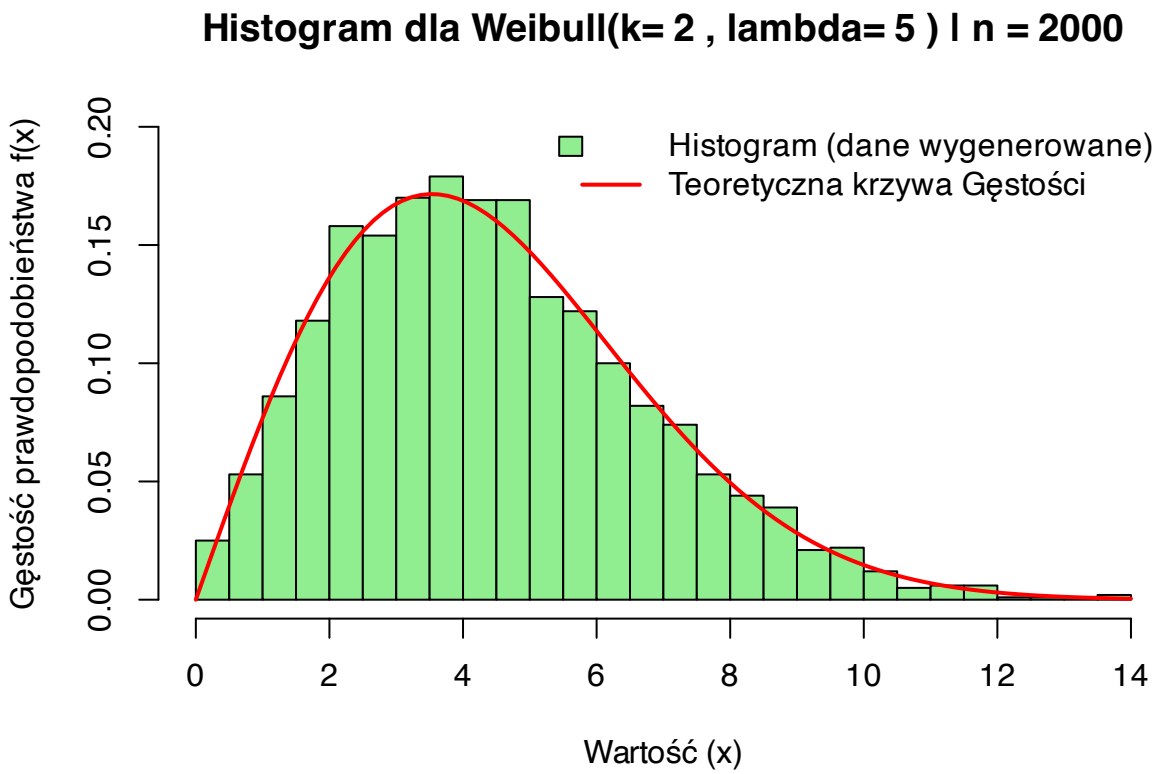

Rysunek 4: Histogram generowanego rozkładu Wiebulla (k=2, lambda=5) na próby wielkości n = 2000

Jak widać nie jest to idealny generator, aczkolwiek jego wyniki są również bardzo zbliżone rzeczywistym.

2.1.3 3.

```r
gen_laplace <- function(n, lambda) {

  if (lambda <= 0) {
    stop("Parametr lambda musi być dodatni")
  }

  u <- runif(n)

  x <- ifelse(
    u < 0.5,
    (1 / lambda) * log(2 * u),
    (-1 / lambda) * log(2 * (1 - u))
```

```
  )

  return(x)
}
```

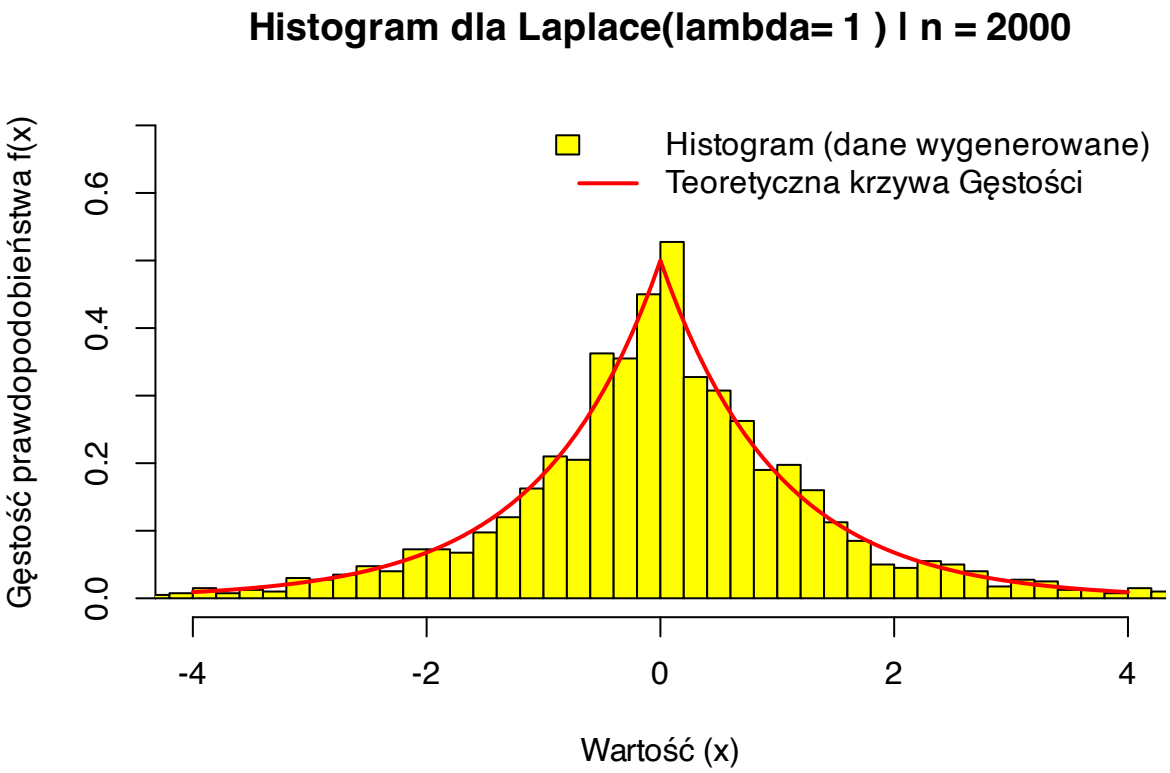

Rysunek 5: Histogram generowanego rozkładu Laplace(lambda=1) dla próby wielkości n = 2000

Jak widać ten generator przynosi równie satysfakcjonujące efekty co poprzednie. Jednak, aby sprawdzić, który z nich jest najdokładniejszy porównam podstawowe wartości do wartości teoretycznych w tabeli poniżej:

Tabela 1: Porównanie średniej i wariancji teoretycznej z empiryczną (n=2000)

Rozkład	Średnia (Teoria)	Średnia (Próba)	Wariancja (Teoria)	Wariancja (Próba)
Wykładniczy	2.0000	2.0876	4.000	4.5290
Weibulla	4.4311	4.4467	5.365	5.3159
Laplace'a	0.0000	0.0098	2.000	1.9133

Zdecydowanie najsłabiej wypada generator wykładniczy, podczas gdy generator weibulla ma najbardziej zbliżoną wariancję, a generetor Laplace ma najbadziej zbliżoną średnią, jednak należy pamiętać, że wyniki zależą od wybranego seed'u oraz wielkości próby, która w tym przypadku była stosunkowo mała.

3 Zadanie 3: Generowanie rozkładu normalnego metodą Boxa-Müllera (4 pkt)

Jak wiadomo z wykładu, jeżeli U_1, U_2 są dwiema niezależnymi zmiennymi z rozkładu jednostajnego na $[0, 1]$, to zmienne

$$X_1 := \sqrt{-2\ln(U_2)}\cos(2\pi U_1), \quad X_2 := \sqrt{-2\ln(U_2)}\sin(2\pi U_1),$$

są dwiema niezależnymi zmiennymi o standardowym rozkładzie normalnym.

1. Napisz funkcję realizującą generator par liczb losowych z rozkładu normalnego (dla zadanych parametrów μ i σ) wykorzystujący powyższą transformację Box-M"ullera
2. Narysuj histogram z nałożoną odpowiednią funkcją gęstości dla próby rozmiaru $n = 5000$ wygenerowanej przy pomocy napisanego generatora.
3. Wygeneruj 2000 realizacji par (X_1, X_2). Wykorzystaj funkcję

```
jointplot <- function(x,y){
  df <- data.frame(x,y)
  scatter <- ggplot(df, aes(x=x,y=y))+geom_bin2d() +
    scale_fill_continuous(type = "viridis") +
    theme_bw()
  hist_right <- ggplot(df)+geom_histogram(aes(y), fill="#69b3a2",
                                          color='darkblue')+
    coord_flip()
  hist_top <- ggplot(df)+geom_histogram(aes(x), fill="#69b3a2",
                                        color='darkblue')

  grid.arrange(hist_top, scatter, hist_right, ncol=2, nrow=2,
               widths=c(4, 1), heights=c(1, 4),
               layout_matrix = rbind(c(1, NA), c(2,3)))}
```

by narysować wykresy łączne rozkładów realizacji par zmiennych:

- X_1 i X_2,
- X_1, $X_1 + X_2$,
- $X_1 + X_2$, $X_1 - X_2$.

4. W każdym z powyższych (trzech) przypadków, oblicz korelacje realizacji obu zmiennych. Czy współrzędne są od siebie niezależne? Wytłumacz.

3.1 Rozwiązanie:

3.1.1 1.

```
gen_normal_boxmuller <- function(n, mu = 0, sigma = 1) {

  if (sigma <= 0) {
    stop("Parametr sigma (odchylenie standardowe) musi być dodatni")
  }
  if (n <= 0 || n %% 1 != 0) {
    stop("n (liczba par) musi być dodatnią liczbą całkowitą")
  }

  u1 <- runif(n)
  u2 <- runif(n)
```

```
  R <- sqrt(-2 * log(u2))

  Theta <- 2 * pi * u1

  z1 <- R * cos(Theta)
  z2 <- R * sin(Theta)

  x1 <- mu + sigma * z1
  x2 <- mu + sigma * z2

  return(cbind(x1, x2))
}
```

3.1.2 2.

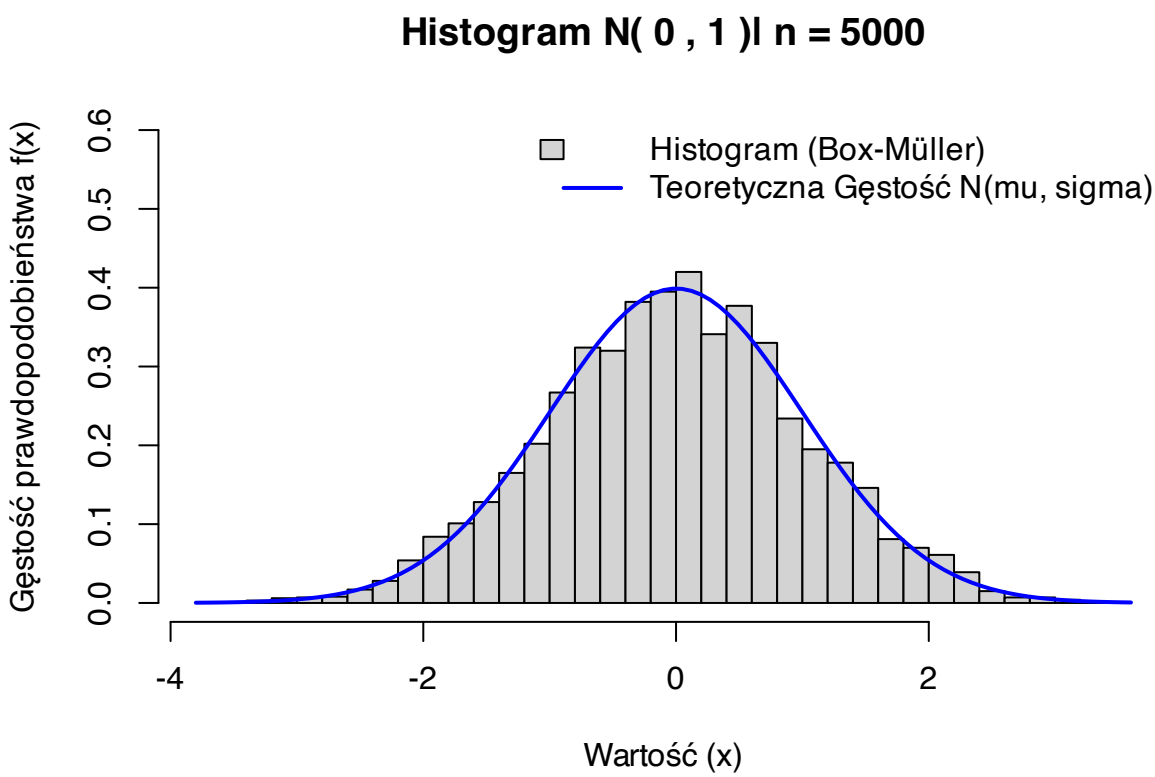

Rysunek 6: Histogram funkcji gętości N(0,1) dla próby rozmiaru n = 5000

3.1.3 3. i 4.

Wykres 1: Rozkład łączny X1 i X2

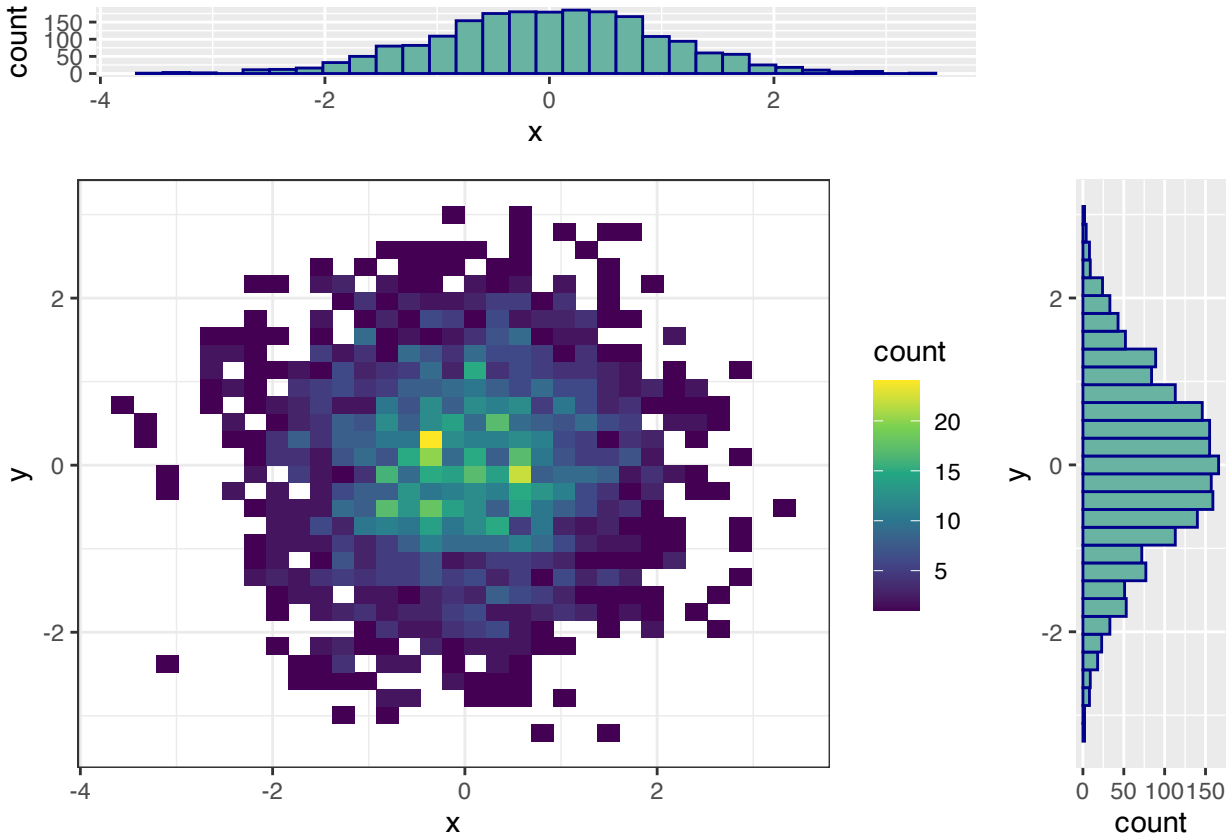

Rysunek 7: Wykres rozkładu łącznego X2 i X1

Współczynnik Korelacji wynosi 0.01569.

Tak niski współczynnik ma jak najbardziej sens, ponieważ zmienne X_1 i X_2 są niezależne.

Wykres 2: Rozkład łączny X1 i (X1 + X2)

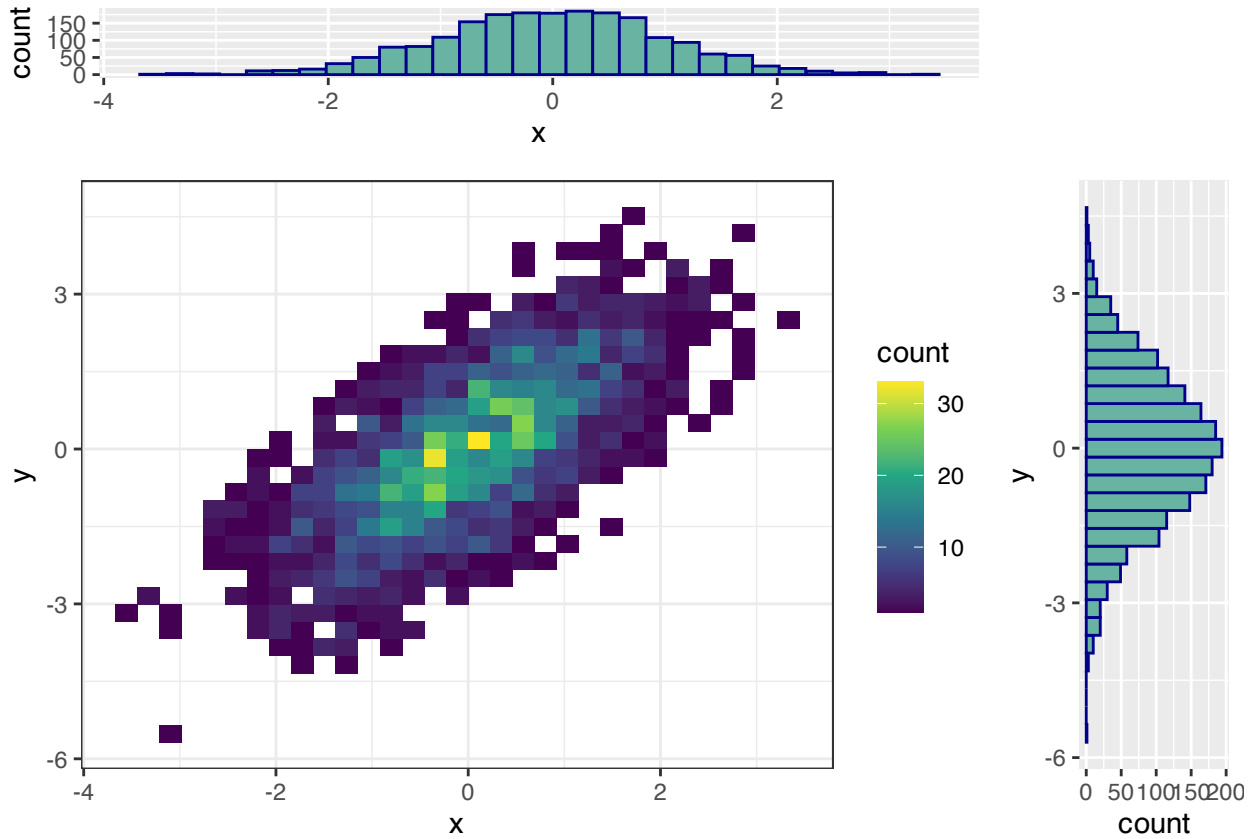

Rysunek 8: Wykres rozkładu łącznego (X1 + X2) i X1

Współczynnik Korelacji wynosi 0.6975.

Ten współczynnik jest zdecydowanie bliżej 1 niż 0, co by miało sens ponieważ zmienne X_1 i $X_1 + X_2$, są od siebie zależne.

Wykres 3: Rozkład łączny (X1 + X2) i (X1 - X2)

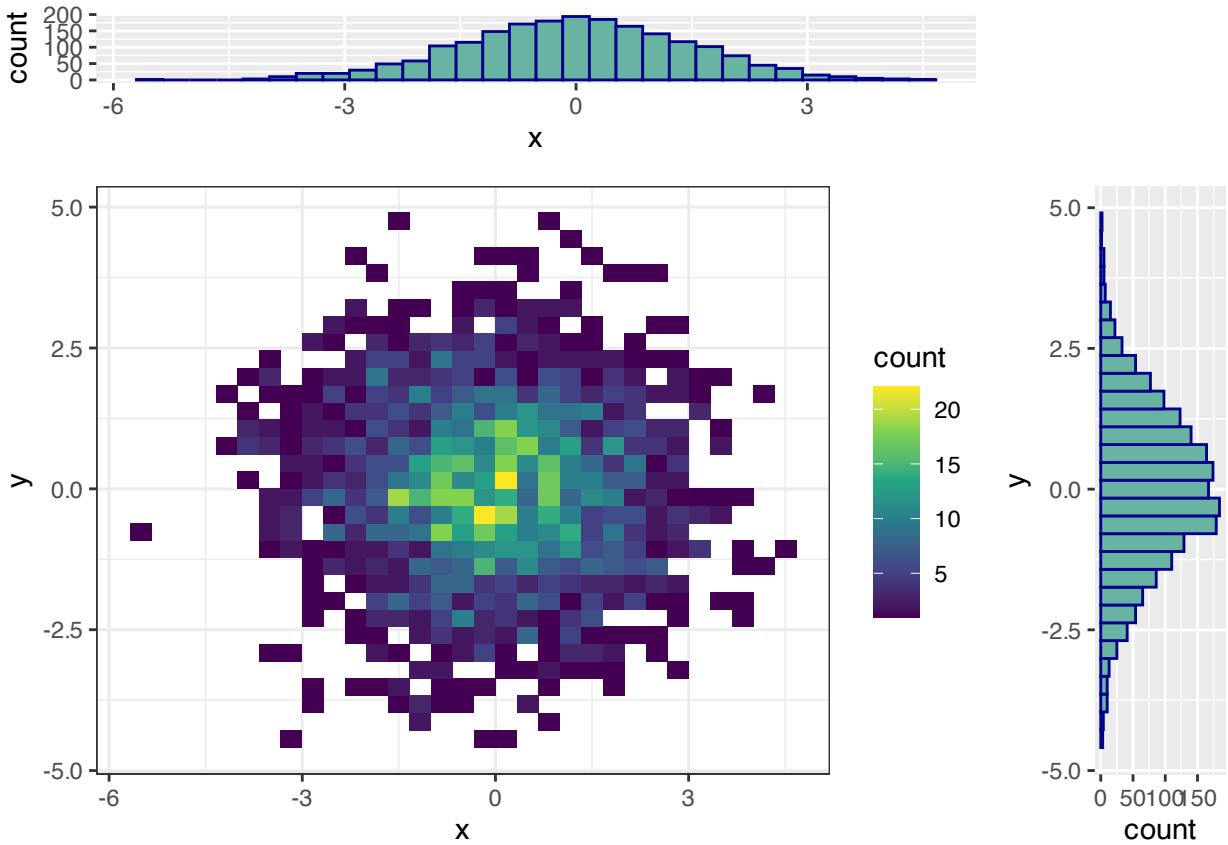

Rysunek 9: Wykres rozkładu łącznego (X1 + X2) i (X1 - X2)

Współczynnik Korelacji wynosi -0.04335.

Ten przypadek moze nie jest aż tak intuicyjny jak poprzednie mimo że współczynnik korelacji nasuwa oczywiste wnioski, aby pokazać że $X_1 + X_2$ i $X_1 - X_2$ są od siebie niezależne postaram się to udowodnić w sposób teoretyczny.

Korzystjąc z liniowości kowariancji:

$$Cov(X_1 + X_2, X_1 - X_2) = Cov(X_1, X_1) - Cov(X_1, X_2) + Cov(X_2, X_1) - Cov(X_2, X_2)$$

Pamiętając że X_1 i X_2 są niezależne i że są z rozkładu normalnego o takiej samej wariancji,

$$Var(X_1) - 0 + 0 - Var(X_2) = 1 - 1 = 0$$

z tego wynika że zmienne rzeczywiście nie są skorelowane.

4 Zad. 4. Metoda akceptacji (3 pkt)

1. Zaproponuj alternatywny sposób generowania prób z rozkładu normalnego oparty na metodzie akceptacji. Jako rozkład majoryzujący rozkład normalny wybierz rozkład Laplace'a i wykorzystaj generator napisany w zadaniu 2.3. Spróbuj wyznaczyć wartości stałej normującej M oraz parametru λ rozkładu Laplace'a, tak by możliwie zminimalizować liczbę odrzucanych próbek.
2. Porównaj czas generowania próby o rozmiarze $n = 10000$ za pomocą napisanego generatora oraz generatora wykorzystującego transformację Boxa-Müllera z zadania 3.

4.1 Rozwiązanie:

4.1.1 1.

Metoda akceptacji polega na znalezieniu stałej M takiej że dla każdego x: f(x) $\leq$ M g(x), gdzie f(x) to gęstość rozkładu, który chcemy generować (Normalny), a g(x) to gęstość rozkładu, z którego potrafimy generować (Laplace).

Szukamy więc supremum ilorazu $\frac{f(x)}{g(x)}$:

$$\frac{f(x)}{g(x)} = \frac{2}{\lambda\sqrt{2\pi}} \exp\left(-\frac{x^2}{2} + \lambda|x|\right)$$

szukając supremum, można oczywiście pominąć wartość bezwzględną ponieważ iloraz jest symetryczny względem osi Y. Pochodna z wykładnika po x wynosi -x + λ. Przyrównując do zera, otrzymujemy maksimum w punkcie x = λ i teraz wstawiam to do ilorazu.

$$M(\lambda) = \sqrt{\frac{2}{\pi}} \frac{1}{\lambda} e^{\lambda^2/2}$$

Chce zminimalizować $M(\lambda)$, więc policzę pochodną $\ln M(\lambda)$ po λ:

$$\frac{d}{d\lambda}\left(\ln\sqrt{\frac{2}{\pi}} - \ln\lambda + \frac{\lambda^2}{2}\right) = -\frac{1}{\lambda} + \lambda$$

Przyrownując do zera wyjdzie oczywiście, że $\lambda = 1$. A podstawiając to do wzoru $M(\lambda)$ wychodzi nam że $M = \sqrt{\frac{2e}{\pi}} \approx 1.3154892$.

```r
#  Generator Normalny metodą Akceptacji
gen_normal_ar <- function(n) {
  lambda_opt <- 1.0
  wynik <- numeric(n)
  ile_mamy <- 0

  while (ile_mamy < n) {
    # Generujemy nieco więcej próbek niż brakuje, żeby na pewno
    # wygenerować odpowiednią ilość zaakceptowanych
    ile_brakuje <- n - ile_mamy
    n_batch <- ceiling(ile_brakuje * 1.4)

    Y <- gen_laplace(n_batch, lambda_opt)
    U <- runif(n_batch)

    # Warunek akceptacji uproszczony matematycznie dla lambda=1
    # log(f(x)/ (M*g(x))) = -0.5 * (|x| - 1)^2
    log_prob_ratio <- -0.5 * (abs(Y) - 1)^2
```

```r
    akceptowane <- Y[log(U) <= log_prob_ratio]

    n_acc <- length(akceptowane)

    if (n_acc > 0) {
      do_dodania <- min(n_acc, ile_brakuje)
      wynik[(ile_mamy + 1):(ile_mamy + do_dodania)] <- akceptowane[1:do_dodania]
      ile_mamy <- ile_mamy + do_dodania
    }
  }

  return(wynik)
}
```

4.1.2 2.

Tabela 2: Wybrane statystyki wydajności (czas w ms)

Generator	Min	Średnia	Max	Ilość powtórzeń
AR_Laplace	779.451	1198.483	8793.106	20
Box_Muller	171.257	190.027	206.722	20

Box-Muller jest zdecydowanie lepszy, bardziej wydajny i nie ma, co do tego żadnych wątpliwości.